

Comparación Empírica de Seis Clasificadores Supervisados para la Predicción Multiclase de Resultados de Fútbol a Escala Multi-Liga (2000–2025)

Curso: Minería de Datos (CC442) — Ciclo Académico 2026-I — Prof. Dr. Marcos Antonio Alania Vicente

Arbúes Pérez
Escuela de Ciencia de la Computación
Universidad Nacional de Ingeniería
Lima, Perú
arbues.perez@uni.pe

Sergio Pezo
Escuela de Ciencia de la Computación
Universidad Nacional de Ingeniería
Lima, Perú
sergio.pezo@uni.pe

Luis Trujillo
Escuela de Ciencia de la Computación
Universidad Nacional de Ingeniería
Lima, Perú
luis.trujillo@uni.pe

Resumen—La predicción del resultado de un partido de fútbol (victoria local, empate o victoria visitante) es un problema de clasificación multiclase notoriamente difícil por el peso del azar y por la clase minoritaria del empate. La literatura previa alcanza gran escala usando métricas probabilísticas y pocos algoritmos, o compara clasificadores con métricas estándar sobre conjuntos pequeños; ninguna ofrece una comparación amplia de clasificadores modernos con métricas por clase y prueba de significancia a gran escala. Este trabajo evalúa de forma controlada nueve familias de modelos (desde una línea base ingenua hasta ensambles apilados) sobre 230 554 partidos de múltiples ligas (2000–2025), empleando exclusivamente información previa al partido y sin cuotas de mercado. Se adopta un protocolo de validación estrictamente temporal y se optimiza la métrica F1 macro por el desbalance de clases. El ensamble por apilamiento propuesto alcanza un F1 macro de 0,419 en el conjunto de prueba y supera a las líneas base con significancia estadística (prueba de Wilcoxon, $p < 0,001$). Se demuestra empíricamente que la frontera del empate es no lineal, que el reponderado por clase supera al sobremuestreo sintético, y que la diferencia de *rating* Elo es la variable dominante según análisis SHAP. Los resultados confirman un techo de rendimiento honesto coherente con el estado del arte y aportan una comparación reproducible que la literatura no tenía.

Index Terms—aprendizaje automático, clasificación multiclase, desbalance de clases, gradient boosting, predicción deportiva, validación temporal

I. INTRODUCCIÓN

La industria del fútbol mueve cifras económicas de gran magnitud y ha convertido la analítica deportiva en una

disciplina de interés científico e industrial. Predecir el resultado de un encuentro tiene aplicaciones en la gestión deportiva, los mercados de apuestas y la generación de contenido; sin embargo, sigue siendo un problema abierto por la alta componente estocástica del juego y por la dificultad estructural de la clase “empate”.

Formalmente, se aborda un problema de clasificación supervisada multiclase. Dado un vector de características $\mathbf{x} \in \mathbb{R}^d$ construido con información disponible *antes* del inicio del partido, se busca una hipótesis $g : \mathbb{R}^d \rightarrow \{H, D, A\}$ que asigne la etiqueta correcta, donde H denota victoria local, D empate y A victoria visitante. El objetivo es aprender g minimizando el error de generalización sobre partidos futuros, sin incurrir en fuga de información temporal.

La motivación técnica de este estudio nace de una brecha concreta en la literatura (Sección II): los trabajos que operan a gran escala emplean métricas probabilísticas como el *Ranked Probability Score* y un repertorio reducido de algoritmos, mientras que los que comparan clasificadores con métricas estándar utilizan conjuntos de datos pequeños. Este trabajo cierra esa brecha con una evaluación amplia, por clase y con contraste de significancia, sobre un conjunto de gran escala.

Las contribuciones concretas son las siguientes:

1. Una comparación empírica controlada de nueve familias de clasificadores —incluyendo los tres motores modernos de *gradient boosting* (XGBoost, LightGBM y CatBoost) y ensambles de tipo *voting* y *stacking*— sobre 230 554 partidos multi-liga, con

reproducibilidad determinista y cómputo en GPU.

2. Un protocolo de evaluación honesto para datos desbalanceados y con deriva temporal: partición por fecha, validación con `TimeSeriesSplit`, optimización de F1 macro y reporte por clase con prueba de Wilcoxon.
3. Evidencia experimental sobre tres cuestiones metodológicas: la naturaleza no lineal de la frontera del empate, la superioridad del reponderado por clase frente al sobremuestreo sintético SMOTE, y la dominancia del *rating* Elo vía análisis SHAP.

El resto de este artículo se organiza de la siguiente manera: la Sección II revisa el estado del arte; la Sección III describe el conjunto de datos y el análisis exploratorio; la Sección IV detalla el preprocesamiento; la Sección V formaliza la metodología y los modelos; la Sección VI documenta la implementación; la Sección VII presenta los resultados y el análisis estadístico; la Sección VIII discute los hallazgos y las amenazas a la validez; y la Sección IX concluye.

II. TRABAJOS RELACIONADOS

La predicción de resultados de fútbol mediante aprendizaje automático cuenta con una literatura consolidada. Rodrigues y Pinto [1] comparan ocho clasificadores sobre la *Premier League* y reportan un mejor resultado con *Random Forest* (exactitud del 65%), con la salvedad de que el empate obtiene una sensibilidad muy baja ($\approx 30\%$). Choi *et al.* [5] estudian el efecto del muestreo y concluyen que el *balanced sampling* permite predecir empates que el muestreo estratificado ignora. Ren y Susnjak [3] comparan modelos incluyendo CatBoost, *voting* y *stacking*, y obtienen un 51,9% de exactitud global, con hasta un 70% en partidos catalogados como “fáciles”. Yeung *et al.* [7] reportan, con XGBoost sobre *features* interpretables, un F1 de 0,47 y una exactitud de 0,57, superando a las cuotas del mercado.

En el extremo de gran escala, Berrar *et al.* [8], [9] trabajan con 216 000 y más de 300 000 partidos de decenas de ligas usando datos “simples” (fecha, equipos, liga y marcador), pero evalúan con el *Ranked Probability Score* y un repertorio reducido de algoritmos (principalmente *k*-NN y *boosting*); en su edición de 2024, ni el mejor modelo logró batir al operador de apuestas. Stübinger *et al.* [6] alcanzan una exactitud del 81,8%, pero mediante una *regresión* de la diferencia de goles con empates excluidos, por lo que su cifra no es comparable con una clasificación de tres vías. Atta Mills *et al.* [10] obtienen 0,83 de exactitud con un ensamble *voting*, aunque incorporando *features* de medio tiempo (*in-game*) que no están disponibles antes del partido. En el plano metodológico, Bunker y Thabtah [2] advierten explícitamente contra la validación cruzada aleatoria en datos con orden temporal y proponen esquemas por rondas, recomendación reforzada por Bunker *et al.* [4].

Es preciso advertir que estas cifras *no* son directamente comparables entre sí, pues los trabajos emplean formu-

Cuadro I
SÍNTESIS DEL ESTADO DEL ARTE Y BRECHA IDENTIFICADA

Trabajo	Escala	Métrica	Mejor modelo / brecha
Rodrigues [1]	1 900	Acc, F1	RF, Acc 0,65
Choi [5]	3 297	Acc, F1, AUC	LogReg mult., Acc 0,54
Ren [3]	1 140	Acc, P/R/F1	CatBoost, Acc 0,52
Yeung [7]	1 700	F1, AUC, Acc	XGBoost, F1 0,47
Berrar [8]	216 743	RPS	<i>k</i> -NN, RPS 0,205
Atta Mills [10]	1 411	Acc, F1	Voting, Acc 0,83 [†]
Este trabajo	230 554	F1/κ/AUC	Stacking + Wilcoxon

[†]Emplea *features* de medio tiempo, no comparables con predicción estrictamente previa al partido.

laciones y métricas heterogéneas —clasificación de tres vías, regresión de la diferencia de goles o puntajes probabilísticos— y subconjuntos de dificultad dispar. Contrastar la exactitud de una regresión con empates excluidos frente a una clasificación multiclase equivaldría a comparar magnitudes distintas. Por ello, el presente estudio fija de antemano un protocolo único (clasificación H/D/A, métricas por clase y validación temporal) y reporta el techo honesto que le corresponde.

La Tabla I sintetiza esta comparación. Del contraste emergen tres consensos: (i) el empate es la clase más difícil, con sensibilidad típicamente inferior al 35%; (ii) el techo realista de exactitud previa al partido en tres clases se sitúa en torno al 52–57%; y (iii) los métodos basados en árboles (*Random Forest* y *gradient boosting*) son ganadores recurrentes. La brecha que este trabajo aborda es clara: ningún estudio compara simultáneamente seis clasificadores modernos —incluidos LightGBM y CatBoost— con métricas por clase y prueba de significancia sobre un conjunto de escala superior a 200 000 partidos multi-liga.

III. DESCRIPCIÓN DEL CONJUNTO DE DATOS Y ANÁLISIS EXPLORATORIO

Se emplea el conjunto público *Club Football Match Data (2000–2025)*, que reúne 230 557 partidos de múltiples ligas internacionales con 48 columnas originales, entre ellas *ratings* Elo, forma reciente, estadísticas del partido y cuotas de mercado. La variable objetivo es $\text{FTResult} \in \{H, D, A\}$. Tras eliminar tres registros sin etiqueta, el conjunto operativo asciende a 230 554 instancias.

El análisis exploratorio revela cuatro propiedades que condicionan todo el modelado. Primero, existe un **desbalance moderado** (Fig. 1): la victoria local representa el 44,6%, la visitante el 28,9% y el empate el 26,5%, con una razón de desbalance de 1,68. Este régimen desaconseja optimizar la exactitud, pues un clasificador que siempre prediga “local” ya alcanzaría $\approx 44\%$.




Figura 1. Distribución de la variable objetivo. La victoria local domina y el empate es la clase minoritaria, lo que motiva optimizar F1 macro en lugar de exactitud.




Figura 2. Distribución del Elo por resultado. La diferencia de calidad separa los tres resultados, pero el empate carece de una región propia, lo que fija un techo estructural a su sensibilidad.

Segundo, la señal principal es la **diferencia de Elo**: al ordenar los partidos por esta variable, la tasa de victoria local, empate y visitante se separa de forma monótona, pero el empate queda siempre en la zona central sin dominar ninguna región (Fig. 2). Esto anticipa una **frontera de decisión no lineal** alrededor del cero, favorable a árboles y *kernels*. Tercero, se detecta **multicolinealidad exacta**: las variables de diferencia son combinaciones lineales de sus componentes, lo que se traduce en factores de inflación de varianza infinitos y en autovalores nulos del análisis de componentes principales. Cuarto, el *rating* Elo presenta ausencias **estructurales por liga** (las competiciones no europeas carecen de él) y el conjunto exhibe **deriva temporal**, con una caída de la ventaja local durante la pandemia.

La Tabla II resume el diccionario de las 62 variables resultantes de la ingeniería de *features*, agrupadas por naturaleza. Todas se calculan con información estrictamente anterior a cada partido.

La estructura de correlación lineal (Fig. 3) hace visible la multicolinealidad: las variables de diferencia forman bloques de correlación perfecta con sus componentes, lo que anticipa la necesidad de regularizar los modelos lineales.

IV. PREPROCESAMIENTO Y JUSTIFICACIÓN MATEMÁTICA

El preprocesamiento se diseñó para respetar la higiene anti-fuga exigida por la naturaleza temporal del proble-

Cuadro II
DICCIONARIO DE VARIABLES DE LA MATRIZ FINAL (62 CARACTERÍSTICAS)

Grupo (n)	Tipo	Descripción
Elo (2)	continua	<i>rating</i> Elo de local y visitante
Forma (4)	continua	puntos en los últimos 3 y 5 partidos
Goles <i>rolling</i> (4)	continua	promedio de goles a favor y en contra (5)
Diferencias (5)	continua	Elo, forma 3/5 y goles a favor/contr
Contexto (7)	continua	descanso, rachas e historial directo
Banderas (2)	binaria	liga top y Elo ausente
Liga (38)	<i>one-hot</i>	división del partido




Figura 3. Matriz de correlación lineal de las variables numéricas. Los bloques de correlación perfecta corresponden a las variables de diferencia y sus componentes, origen de la multicolinealidad exacta.

ma. Se descartaron las columnas posteriores al partido (estadísticas de juego, marcador y variables de medio tiempo), que constituyen fuga directa, y —por decisión de diseño— las cuotas de mercado, con el fin de evaluar el poder predictivo “honesto” del sistema sin la muleta del operador de apuestas.

El *rating* Elo se reconstruyó mediante una unión temporal (*merge-asof*) con la restricción fecha $\leq$ fecha del partido para evitar fuga, y las ausencias estructurales se señalaron con una bandera explícita. A partir de las variables seguras se construyó un conjunto de *features* de ingeniería —diferencia de Elo, forma reciente, promedios móviles de goles a favor y en contra, historial directo, días de descanso, rachas y pertenencia a liga top— calculados únicamente con partidos anteriores a cada fila.

La partición es **estrictamente temporal**: entrenamiento hasta 2021 (191 099 instancias), validación 2022–2023 (24 669) y prueba 2024–2025 (14 786), con frontera verificada. La justificación teórica es la desigualdad de generalización: la cota de Vapnik–Chervonenkis exige fijar la hipótesis *antes* de tocar el conjunto de evaluación, y una validación cruzada aleatoria sobre datos temporales introduciría partidos del futuro en el entrenamiento, sesgando la estimación del error.

La estandarización de las variables continuas se calculó **solo sobre el entrenamiento** y se aplicó de forma ciega al resto:

$$x'_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad (1)$$




Figura 4. Varianza acumulada del análisis de componentes principales sobre las variables continuas. El 95 % se alcanza con 13 componentes; los cinco autovalores nulos reflejan la colinealidad exacta de las variables de diferencia.




Figura 5. Diagrama de bloques del *pipeline* metodológico.

donde μ_j y σ_j son la media y la desviación estándar de la característica j estimadas en el entrenamiento. Las variables de liga se codificaron con *one-hot*, resultando una matriz final de **62 características**. Como control de la multicolinealidad, se computa un análisis de componentes principales sobre las variables continuas: la varianza acumulada alcanza el 95% con 13 componentes (Fig. 4), y aparecen cinco autovalores nulos que confirman las cinco dependencias lineales exactas detectadas en el análisis exploratorio.

V. METODOLOGÍA PROPUESTA

La Fig. 5 resume el *pipeline*. Sobre la matriz procesada se entrena un conjunto de clasificadores, cuyos hiperparámetros se seleccionan mediante validación temporal interna, y el mejor de cada familia se compara sobre el conjunto de validación antes de la evaluación final en prueba.

V-A. Protocolo de validación y métrica

La selección de hiperparámetros se realiza *dentro* del entrenamiento con `TimeSeriesSplit` de cinco pliegues expansivos, cuyo puntaje es el promedio de F1 macro:

$$\text{CV}(\lambda) = \frac{1}{K} \sum_{i=1}^K \text{F1}_{\text{macro}}(g_{\lambda,i}^-). \quad (2)$$

La métrica de optimización es la **F1 macro**, que pondera por igual las tres clases y penaliza ignorar el empate:

$$\text{F1}_{\text{macro}} = \frac{1}{3} \sum_{c \in \{H,D,A\}} \frac{2P_c R_c}{P_c + R_c}. \quad (3)$$

El reporte final incluye *precision*, *recall* y F1 por clase, el coeficiente κ de Cohen, el área bajo la curva ROC

uno-contra-el-resto, la matriz de confusión y la pérdida logarítmica.

V-B. Modelos y fundamentos

Se evaluaron nueve familias. Como **líneas base**, un clasificador ingenuo (clase mayoritaria) y *Naive Bayes* gaussiano, $\hat{y} = \arg \max_c P(c) \prod_j P(x_j | c)$, cuyo supuesto de independencia lo penaliza en presencia de variables correlacionadas. Como **modelos lineales/de margen**, la **regresión logística multinomial** con regularización de Tikhonov,

$$\mathcal{L} = - \sum_i \log P(y_i | x_i) + \lambda \|W\|^2, \quad (4)$$

donde el término $\lambda \|W\|^2$ vuelve invertible la matriz singular por la colinealidad; y la **máquina de vectores de soporte**, que maximiza el margen $1/\|w\|$ y cuyo *kernel* de base radial $K(x, x') = \exp(-\gamma \|x - x'\|^2)$ habilita fronteras no lineales.

Como **métodos de árbol**, un **árbol de decisión** que maximiza la ganancia de información $IG(Y, X) = H(Y) - H(Y | X)$; un **Random Forest**, cuya varianza del promedio de B árboles con correlación ρ es $\rho^2 + \frac{1-\rho}{B} \sigma^2$, reducida al descorrelacionar mediante selección aleatoria de atributos; y **AdaBoost**, que combina aprendices débiles con $\alpha_m = \frac{1}{2} \ln \frac{1-\epsilon_m}{\epsilon_m}$. Como **valor añadido**, los tres motores de *gradient boosting* (XGBoost, LightGBM y CatBoost), que ajustan en cada ronda un árbol al gradiente de la pérdida con regularización de segundo orden:

$$\mathcal{L}^{(t)} \approx \sum_i \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \gamma T + \frac{1}{2} \lambda \|w\|^2, \quad (5)$$

y un **ensamble** (*voting* y *stacking*) que, por el teorema del jurado de Condorcet, mejora el consenso de modelos diversos.

V-C. Selección de hiperparámetros

Cada hiperparámetro clave se barre por curva de validación sobre `TimeSeriesSplit`, eligiendo el punto donde la validación deja de mejorar (control del compromiso sesgo-varianza). La Tabla III resume los espacios de búsqueda; los *boosting* usan además parada temprana sobre el conjunto de validación. El desbalance se maneja con `class_weight` balanceado como estrategia primaria y con SMOTE como experimento controlado. Todo el cómputo fija la semilla en 42.

VI. IMPLEMENTACIÓN DEL SOFTWARE

El sistema se implementó en Python 3.12 con *scikit-learn*, XGBoost, LightGBM, CatBoost, *imbalanced-learn* y SHAP. El código sigue una arquitectura modular en `src/`, organizada por fase (`eda`, `preprocessing`, `modeling`), donde cada modelo es un *script* autocontenido que comparte un núcleo común (`_common.py`) con la carga de datos, el esquema de validación, el cálculo de métricas y la generación de figuras. La reproducibilidad determinista se garantiza fijando la semilla global (`random_state=42`)

Cuadro III
ESPACIOS DE BÚSQUEDA DE HIPERPARÁMETROS

Modelo	Rango	Búsque- da
Logística	$C \in \{10^{-2}, \dots, 10^1\}$, L2	Grid
Árbol	max_depth 3–20, min_leaf 1–200	Grid
SVM-RBF	$C \in \{0, 1 \dots 100\}$, $\gamma \in \{\text{escala}, 10^{-3} \dots 1\}$	Random
Random Forest	n_est 250–550, max_feat $\{\sqrt{\cdot}, 0.3\}$	Random
XGB/LGBM	lr 0.02–0.3, $depth$, $subsample$	Random
CatBoost	$depth$ 4–10, $l2_leaf_reg$ 1–10	Random

en Python, NumPy y en cada estimador, búsqueda y pliegue. El entrenamiento de los modelos de *boosting* se aceleró en GPU (NVIDIA RTX 3060) mediante `device='cuda'` en XGBoost y `task_type='GPU'` en CatBoost. Cada *script* vuelca sus métricas y tiempos a `results/` y sus figuras a `figures/`, y el cuaderno `3.0-modeling-evaluation.ipynb` reproduce la metodología de principio a fin sin errores.

En cuanto al costo computacional, la aceleración por GPU resultó decisiva para los modelos de *boosting*: la búsqueda de hiperparámetros de XGBoost sobre las 191099 instancias de entrenamiento requirió del orden de siete minutos, y la de CatBoost, de veinticuatro. LightGBM se ejecutó finalmente en CPU tras constatar que, en un conjunto de este tamaño, la recompilación del *kernel* de cómputo en cada ajuste domina el tiempo y anula la ventaja de la GPU. Los modelos lineales y de árbol se entrenaron en segundos. El SVM de *kernel* radial, cuyo costo es cuadrático en el número de muestras, se ajustó sobre una submuestra estratificada de 35 000 partidos que preserva el orden cronológico, decisión documentada de forma explícita para no ocultar el submuestreo.

VII. RESULTADOS EXPERIMENTALES Y ANÁLISIS ESTADÍSTICO

La Tabla IV presenta el desempeño en el conjunto de prueba (2024–2025), ordenado por F1 macro. Todos los modelos competentes se agrupan en torno a un F1 macro de 0,42 y una exactitud de 0,44, coherente con el techo honesto de la literatura para la predicción previa al partido sin cuotas de mercado.

La Tabla V desglosa el F1 por clase para un subconjunto representativo de modelos. El contraste es elocuente: la victoria local alcanza un F1 cercano a 0,52, mientras que el empate no supera 0,31 en ningún caso. El SVM lineal ilustra el extremo patológico: obtiene el mayor F1 de local (0,61) a costa de un F1 del empate prácticamente nulo, es decir, predice “local” de forma casi sistemática. El SVM de *kernel* radial, en cambio, sacrifica algo de F1 en local para lograr el mejor desempeño en el empate.

Cuadro IV
RESULTADOS EN EL CONJUNTO DE PRUEBA (2024–2025), ORDENADOS POR F1 MACRO

Modelo	F1 _{mac}	Acc	κ	AUC	R _D
Stacking (prop.)	0,419	0,438	0,146	0,610	0,264
LightGBM	0,419	0,444	0,149	0,613	0,235
Random Forest	0,417	0,446	0,149	0,614	0,213
XGBoost	0,416	0,439	0,143	0,609	0,245
CatBoost	0,415	0,442	0,146	0,615	0,221
Voting	0,414	0,443	0,146	0,612	0,213
SVM-RBF	0,413	0,424	0,134	0,606	0,314
Reg. Logística	0,412	0,439	0,142	0,607	0,214
Árbol	0,408	0,434	0,136	0,608	0,218
AdaBoost	0,395	0,413	0,117	0,596	0,239
Naive Bayes	0,392	0,412	0,103	0,576	0,235
SVM lineal	0,335	0,472	0,113	0,604	0,004
Dummy (piso)	0,202	0,434	0,000	0,500	0,000

Cuadro V
F1 POR CLASE EN EL CONJUNTO DE PRUEBA (MODELOS SELECCIONADOS)

Modelo	F1 _H	F1 _D	F1 _A	R _D
Stacking (prop.)	0,515	0,280	0,462	0,264
LightGBM	0,524	0,267	0,465	0,235
SVM-RBF	0,482	0,305	0,453	0,314
Reg. Logística	0,520	0,250	0,465	0,214
SVM lineal	0,612	0,008	0,384	0,004

VII-A. La trampa de la exactitud

La comparación con la línea base ingenua es decisiva. El clasificador *Dummy*, que siempre predice la clase mayoritaria, alcanza una exactitud de 0,434 —apenas por debajo del 0,44 del mejor modelo—, pero su F1 macro es de solo 0,202 y su κ es nulo. La exactitud, por tanto, *no* distingue un modelo útil de uno inútil en presencia de desbalance. La superioridad real del sistema se manifiesta en el F1 macro (que se duplica), en el coeficiente κ (que pasa de 0 a $\approx 0,15$) y en el AUC (de 0,50 a 0,61). La Fig. 6 ilustra este contraste en validación y prueba.

VII-B. Análisis de la matriz de confusión

La matriz de confusión del modelo propuesto (Fig. 7) confirma la hipótesis del análisis exploratorio: el empate se confunde sistemáticamente con la victoria local y la visitante, y casi nunca existe una región donde *D* sea la predicción mayoritaria. Su sensibilidad máxima entre todos los modelos la alcanza el SVM de *kernel* radial (0,314), lo que refuerza la naturaleza no lineal de su frontera.

VII-C. Experimento de desbalance

La Tabla VI compara tres estrategias con una configuración de XGBoost fija. Sin balanceo, el modelo prácticamente no predice empates (sensibilidad de *D* de 0,008), a pesar de una exactitud mayor. El reponderado por clase es la única estrategia que eleva simultáneamente el F1 macro y la sensibilidad del empate. SMOTE apenas ayuda: al




Figura 6. F1 macro por modelo en validación y prueba. La línea de referencia marca el ancla de la regresión logística; el pelotón “real” se agrupa muy por encima del piso ingenuo (F1 macro 0,20).




Figura 7. Matriz de confusión del modelo propuesto (Stacking) en prueba. El empate se reparte entre local y visitante, evidenciando su techo estructural.

interpolan entre empates —además sobre variables *one-hot*— genera puntos que caen en zonas ya dominadas por otras clases, sin crear frontera nueva, coherente con la ausencia de región propia del empate.

VII-D. Interpretabilidad

El análisis SHAP sobre el modelo de *boosting* (Fig. 8) identifica la **diferencia de Elo** como la variable dominante, muy por encima del historial directo, la forma reciente y el balance de goles. Este resultado coincide con la importancia por permutación del *Random Forest* y confirma cuantitativamente la lectura del análisis exploratorio: la diferencia de calidad entre equipos explica la mayor parte de lo predecible.

Este hallazgo se corrobora con un método independiente: la importancia por permutación del *Random Forest* (Fig. 9), que mide la caída de F1 macro al permutar cada variable, sitúa nuevamente a la diferencia de Elo muy

Cuadro VI
ESTRATEGIAS DE DESBALANCE (XGBOOST FIJO, VALIDACIÓN)

Estrategia	F1 macro	Recall D	Exactitud
Sin balanceo	0,348	0,008	0,484
class_weight	0,425	0,243	0,449
SMOTE	0,356	0,016	0,484




Figura 8. Importancia global por valores SHAP sobre XGBoost. La diferencia de Elo domina la predicción, seguida del historial directo y la forma reciente.

por delante del resto. La coincidencia de dos técnicas de atribución distintas refuerza la robustez de la conclusión.

VII-E. Significancia estadística

Para descartar que la ventaja del modelo propuesto sea producto del azar, se aplicó la prueba de Wilcoxon de rangos con signo ($\alpha = 0,05$) sobre el F1 macro calculado por bloque temporal mensual en el conjunto de prueba ($n = 17$ bloques). El *stacking* supera al clasificador ingenuo ($p = 7,6 \times 10^{-6}$) y al *Naive Bayes* ($p = 6,7 \times 10^{-4}$), ambos resultados estadísticamente significativos. La mejora, por tanto, es consistente a lo largo del tiempo y no atribuible a variabilidad experimental.

VIII. DISCUSIÓN

Los resultados admiten una lectura unificada a partir de las propiedades detectadas en el análisis exploratorio. El liderazgo (marginal) de los métodos de *boosting* y del ensamble, junto con el contraste entre el SVM lineal —que hunde la sensibilidad del empate a casi cero— y el SVM de *kernel* radial —que la eleva a 0,31—, confirma que la frontera de decisión es no lineal. Sin embargo, la agrupación estrecha de todos los modelos competentes indica que, en ausencia de cuotas de mercado, la señal disponible tiene un techo bajo, y ningún algoritmo lo supera de forma dramática. El empate actúa como muro estructural: no ocupa una región propia del espacio de *features*, por lo que su sensibilidad está acotada con independencia del clasificador. El *stacking* obtiene la mejor F1 macro porque




Figura 9. Importancia por permutación del *Random Forest* sobre validación. La caída de F1 macro al permutar la diferencia de Elo supera con creces a la del resto de variables, en coincidencia con el análisis SHAP.

su meta-modelo aprende a ponderar la fortaleza de cada base según la región del espacio.

Amenazas a la validez interna. El principal riesgo, la fuga temporal, se mitiga con la partición por fecha y la validación con `TimeSeriesSplit`; la ausencia de exactitudes sospechosamente altas ($> 65\%$) es coherente con un pipeline sin fuga. El ensamble por apilamiento emplea un esquema de validación interno estratificado para generar las predicciones fuera de pliegue, mientras la integridad temporal se preserva en el nivel externo, con validación y prueba intactas.

Amenazas a la validez externa. El modelo se entrenó sin cuotas de mercado, por lo que su techo es inherentemente inferior al de sistemas que las incorporan; su capacidad de generalización a ligas o temporadas con dinámicas muy distintas (por ejemplo, la deriva observada durante la pandemia) no está garantizada. Además, la ausencia estructural de Elo en ligas no europeas limita la homogeneidad de la señal entre competiciones.

VIII-A. Consideraciones éticas

El conjunto de datos no contiene atributos personales sensibles —género, etnia o condición socioeconómica de individuos—: las entidades son clubes y sus estadísticas deportivas agregadas, por lo que no procede un análisis de sesgos demográficos. No obstante, un sistema de predicción de resultados deportivos puede emplearse en mercados de apuestas; su uso responsable exige comunicar con transparencia la elevada incertidumbre del modelo —evidenciada por el techo de rendimiento— y no presentarlo como una herramienta de ganancia garantizada.

IX. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo presentó una comparación empírica reproducible de nueve familias de clasificadores para la predicción multiclase de resultados de fútbol sobre 230 554

partidos multi-liga, con un protocolo de validación temporal y métricas robustas al desbalance. Las conclusiones técnicas son tres. Primero, el empate constituye un límite estructural: ningún modelo superó un F1 macro global de 0,42 ni una sensibilidad del empate por encima de 0,33, no por deficiencia de los algoritmos sino por la geometría del problema. Segundo, la frontera es no lineal, como evidencian el contraste SVM lineal frente a *kernel* radial y el liderazgo del *boosting* y el *stacking*; el reponderado por clase resultó superior al sobremuestreo sintético, y la diferencia de Elo es la variable dominante según SHAP. Tercero, el modelo propuesto supera a las líneas base con significancia estadística, lo que valida la contribución frente al azar experimental.

Como trabajo futuro se plantea incorporar las cuotas de mercado como *features* para cuantificar el salto de rendimiento respecto de la versión honesta, modelar la incertidumbre del empate mediante salidas probabilísticas calibradas y la métrica RPS, y explorar arquitecturas secuenciales que capturen la forma de los equipos como serie temporal.

REFERENCIAS

- [1] F. Rodrigues and Â. Pinto, “Prediction of football match results with Machine Learning,” *Procedia Computer Science*, vol. 204, pp. 463–470, 2022.
- [2] R. Bunker and F. Thabtah, “A machine learning framework for sport result prediction,” *Applied Computing and Informatics*, vol. 15, no. 1, pp. 27–33, 2019.
- [3] Y. Ren and T. Susnjak, “Predicting football match outcomes with explainable machine learning,” *arXiv:2211.15734*, 2022.
- [4] R. Bunker, C. Yeung, and K. Fujii, “Machine learning in sports: A survey and future directions,” *arXiv:2403.07669*, 2024.
- [5] B. Choi, L. Foo, and G. Chua, “Predicting football match outcomes with machine learning approaches,” *MENDEL*, vol. 29, no. 2, pp. 229–236, 2023.
- [6] J. Stübinger, B. Mangold, and J. Knoll, “Machine learning in football betting: Prediction of match results based on player characteristics,” *Applied Sciences*, vol. 10, no. 1, art. 46, 2020.
- [7] C. Yeung, R. Bunker, and K. Fujii, “A framework of interpretable match results prediction in football,” *PLOS ONE*, vol. 18, no. 4, e0284318, 2023.
- [8] D. Berrar, P. Lopes, and W. Dubitzky, “Incorporating domain knowledge in machine learning for soccer outcome prediction,” *Machine Learning*, vol. 108, pp. 97–126, 2019.
- [9] D. Berrar, P. Lopes, and W. Dubitzky, “Predicting soccer results through ensemble learning,” *Machine Learning*, vol. 113, 2024.
- [10] E. F. E. Atta Mills *et al.*, “Football match outcome prediction using machine learning,” *Journal of Big Data*, vol. 11, art. 170, 2024.
- [11] A. C. Constantinou and N. E. Fenton, “Determining the level of ability of football teams by dynamic ratings,” *Journal of Quantitative Analysis in Sports*, vol. 9, no. 1, pp. 37–50, 2013.
- [12] M. J. Dixon and S. G. Coles, “Modelling association football scores and inefficiencies in the football betting market,” *Applied Statistics*, vol. 46, no. 2, pp. 265–280, 1997.
- [13] L. M. Hvattum and H. Arntzen, “Using ELO ratings for match result prediction in association football,” *International Journal of Forecasting*, vol. 26, no. 3, pp. 460–470, 2010.
- [14] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [15] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.

- [16] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD*, 2016, pp. 785–794.
- [17] G. Ke *et al.*, “LightGBM: A highly efficient gradient boosting decision tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [18] L. Prokhorenkova *et al.*, “CatBoost: unbiased boosting with categorical features,” in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [19] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [20] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.