

Clasificación Multiclase de Resultados de Fútbol a Escala Multi-Liga con Validación Temporal y Análisis de Significancia Estadística

Minería de Datos (CC442) — 2026-I

Arbués Pérez Villegas Luis Trujillo Serva Sergio Pezo Jimenez

Universidad Nacional de Ingeniería — Ciencia de la Computación

Julio 2026

Agenda

Arbués — Datos

- 1 Motivación y problema
- 2 Objetivos
- 3 Dataset y EDA
- 4 Preprocesamiento

Sergio — Metodología

- 5 Arquitectura y validación
- 6 Modelos y fundamentos

Luis — Validación

- 7 Resultados y métricas
- 8 Significancia (Wilcoxon)
- 9 Interpretabilidad (SHAP)
- 10 Discusión y conclusiones

- Predecir **local** / **empate** / **visitante** es un problema clásico de analítica deportiva.
- Difícil por dos razones:
 - marcador bajo $\Rightarrow$ el **azar** pesa mucho;
 - el **empate** es clase minoritaria y esquiva.
- Pregunta de investigación: *¿cuánto se puede predecir de forma honesta, sin usar las cuotas del mercado?*

Definición formal del problema

Clasificación supervisada multiclase:

$$g : \mathbb{R}^d \rightarrow \{H, D, A\}$$

- $\mathbf{x} \in \mathbb{R}^d$: características **previas** al partido.
- H local, D empate, A visitante.
- Restricción **temporal**: nada de lo ocurrido durante/después del partido entra en $\mathbf{x}$.

Objetivos

General

Diseñar un pipeline reproducible y **sin fuga de datos** que compare nueve familias de modelos.

Específicos


- Líneas base (Dummy, Naive Bayes).
- Modelos del curso con fundamentación matemática.
- Gradient boosting moderno + ensamble.
- Métricas por clase y prueba de significancia.

Club Football Match Data (2000–2025)


- $N = 230\,554$ partidos, múltiples ligas internacionales.
- Objetivo: $\text{FTResult} \in \{H, D, A\}$.
- Información pre-partido: Elo, forma, goles, historial. **Sin cuotas.**
- Escala superior a la literatura habitual (una liga, pocos miles).

EDA I — Desbalance de clases

- H 44,6% A 28,9% D 26,5%
- Razón de desbalance = 1,68.
- **Consecuencia:** optimizar *accuracy* premiaría al que siempre dice “local”.
- $\Rightarrow$ optimizamos **F1 macro**.



EDA II — Elo y multicolinealidad



- La **diferencia de Elo** separa $H > D > A$, pero el empate queda *en el medio*.
- $\Rightarrow$ frontera **no lineal** (favorece árboles/kernels).
- Multicolinealidad exacta ($VIF \rightarrow \infty$; 5 autovalores nulos).
- Elo ausente estructuralmente + deriva temporal (COVID).

Pipeline de preprocesamiento

Datos crudos → limpieza anti-fuga → reconstrucción de Elo → ingeniería de *features* → **partición temporal** → estandarización (*fit* en train) → modelado

- Se descartan columnas post-partido (fuga) y cuotas (versión honesta).
- Estandarización y encoders ajustados **solo en entrenamiento**.

- **Elo faltante** (~35%): NO imputar con 0.
 - Reconstrucción por unión temporal (fecha $\leq$ fecha del partido).
 - Ausencia estructural $\rightarrow$ bandera `elo_missing`.
- Forma y goles: imputación por mediana de entrenamiento.
- Estandarización Z-score con parámetros del train:

$$x'_{ij} = \frac{x_{ij} - \mu_{j,\text{train}}}{\sigma_{j,\text{train}}}$$

62 características (solo pasado):

- diferencias de Elo, forma, goles;
- historial directo, descanso, rachas;
- banderas + one-hot de liga.

Partición temporal

- train $\leq$ 2021 (191k)
- val 2022–2023 (25k)
- test 2024–2025 (15k)

K-fold aleatorio = fuga.

- Hiperparámetros: TimeSeriesSplit (5) **dentro** de train.
- Selección entre familias: conjunto de **validación** (2022–2023).
- Reporte final: conjunto de **prueba** (2024–2025), intacto.
- Métrica optimizada: **F1 macro**

$$F1_{\text{macro}} = \frac{1}{3} \sum_{c \in \{H, D, A\}} \frac{2P_c R_c}{P_c + R_c}$$

- **Regresión logística** (softmax + L2 = Tikhonov):

$$\mathcal{L} = - \sum_i \log P(y_i | x_i) + \lambda \|W\|^2$$

la L2 vuelve invertible la matriz singular por colinealidad.

- **SVM**: maximiza el margen $1/\|w\|$; *kernel* RBF $K(x, x') = \exp(-\gamma\|x - x'\|^2) \Rightarrow$ frontera no lineal.
- **Árbol**: maximiza la ganancia de información $IG = H(Y) - H(Y | X)$.

Modelo B — ensambles y boosting

- **Random Forest**: bagging; al restringir a $m < p$ atributos **descorrelaciona** los árboles (baja ρ , baja varianza).
- **Gradient boosting** (XGBoost/LightGBM/CatBoost): ajusta el gradiente de la pérdida con 2.º orden:

$$\mathcal{L}^{(t)} \approx \sum_i \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t)$$

- **Stacking** (propuesto): meta-modelo sobre bases diversas (Condorcet).


Resultados experimentales (test)

Modelo	$F1_{\text{mac}}$	Acc	κ	AUC	R_D
Stacking (prop.)	0,419	0,438	0,146	0,610	0,264
LightGBM	0,419	0,444	0,149	0,613	0,235
XGBoost	0,416	0,439	0,143	0,609	0,245
SVM-RBF	0,413	0,424	0,134	0,606	0,314
Naive Bayes	0,392	0,412	0,103	0,576	0,235
Dummy (piso)	0,202	0,434	0,000	0,500	0,000


El pelotón competente se agrupa en $\approx 0,42$ de F1 macro.

La trampa de la *accuracy*


- Dummy: accuracy **0,434**, pero F1 macro **0,20**, $\kappa = 0$: **inútil**.
- Propuesto: misma accuracy aparente, pero
 - F1 macro $0,20 \rightarrow 0,42$ (**el doble**)
 - $\kappa : 0 \rightarrow 0,15$; AUC: $0,50 \rightarrow 0,61$
- La accuracy **engaña** bajo desbalance.



Visualizaciones del rendimiento




El empate se lo reparten H y A.



ROC OvR del modelo propuesto.

- Prueba de rangos con signo ($\alpha = 0,05$) sobre F1 macro por bloque mensual ($n = 17$).
- Propuesto (Stacking) vs. líneas base:
 - vs. Dummy: $p = 7,6 \times 10^{-6}$ **significativo**
 - vs. Naive Bayes: $p = 6,7 \times 10^{-4}$ **significativo**
- $\Rightarrow$ la mejora **no** es producto del azar.

Interpretabilidad — SHAP



- `elo_diff` domina la predicción.
- Le siguen historial directo, forma y goles recientes.
- Confirmado por importancia de permutación (RF): *dos métodos, misma conclusión.*

- **No linealidad:** LinearSVC hunde recall_D a 0,004; SVM-RBF lo sube a 0,31.
- **Desbalance:** `class_weight` > SMOTE (el empate no tiene región propia).
- **Validez interna:** sin fuga (no hay accuracies > 65%).
- **Validez externa:** sin cuotas $\Rightarrow$ techo inferior; deriva temporal no garantizada.

Conclusiones y trabajo futuro

Conclusiones

- 1 El empate es un **límite estructural**, no una falla de los algoritmos.
- 2 Frontera no lineal; `class_weight` > SMOTE; `elo_diff` domina.
- 3 El propuesto supera a las bases con **significancia estadística**.

Trabajo futuro

Incorporar cuotas (medir el salto), calibrar la incertidumbre del empate (RPS), modelos secuenciales de la forma.

Gracias

Repositorio del proyecto y artículo IEEE:

<https://github.com/Arbues/football-prediction>

¿Preguntas?